



ÚSTAV AUTOMATIZACE A INFORMATIKY

VSV – Strojové vidění

Jméno: Černák, Michalica, Mikuš, Stebnický		ID studenta: -
Datum zadání: 20.11.2023	Datum odevzdání: 22.01.2024	Studijní skupina: 5pAIŘ/1
Název úlohy: Kontrola kvality kabelů		

ZADÁNÍ ÚLOHY

Zákazník potřebuje zajistit automatizovanou kontrolu správného nasazení koncovky na vodič. Vodičem je lankový kabel. U vodiče se správně nasazeným konektorem nesmí odstávat žádné lanko kabelu. V případě, že je detekováno volně přístupné lanko, vrací systém "Fail", jinak vrací "Pass".

ROZBOR ÚLOHY

Úloha pozostává v rozdělení káblů do dvou tříd, "Fail" a "Pass", takže úloha je problémem binárního klasifikátoru. Do třídy "Pass" patří káble bez žiadneho otřepu a do třídy "Fail" káble s otřepem.

Kvôli nedostatku vzorkov bude nutné rozšíriť dataset. Keďže budú detekované malé odchýlky od normálu tak nie je potrebné disponovať príliš veľkým datasetom.

Z dôvodu rôznej farby káblov je bude nutné zvoliť vhodnú podložku a svetlo, pretože nevhodnou voľbou môžeme stratiť telá káblov určitých farieb.

Presnosť klasifikácie sa počíta podľa rovnice 1, kde TP je true positive, FP je false positive, TN je true negative a FN false negative. TP je počet správne klasifikovaných objektov triedy "Pass", TN je počet správne klasifikovaných objektov triedy "Fail", FP je počet

$$Acc = \frac{TP+TN}{TP+FP+TN+FN} \quad (1)$$

nesprávne klasifikovaných objektov do triedy “Pass” a FN je počet nesprávne klasifikovaných objektov do triedy “Fail”.

HARDWARE


Tab. 1 Použitý hardware

Zariadenie:	Výrobca:	Typ:	Rozlíšenie:	Vlastnosti:	Svetelnosť:	Ohnisková vzdialenosť:
Kamera	Basler	ace2500 - 60um	2590x2048 px	monochromatická		
Objektív	Kowa	LM12SC	x	x	1,8	12 mm
Svetlo	VST	VL-DR5090RGB		24V/7.5W		
Zdroj	VST	VLP-2430-3		100-240V		




Obr. 1 Použitý Hardware

SCHÉMA




Obr. 2 Schéma pracovního prostoru

HLAVNÍ SCÉNA



Obr. 3 Fotka pracovního prostoru

Ukážka dobrého a zlého káblu:



Obr. 4 Dobrý (vpravo) a zlý (vľavo) kábel

PRACOVNÍ POSTUP

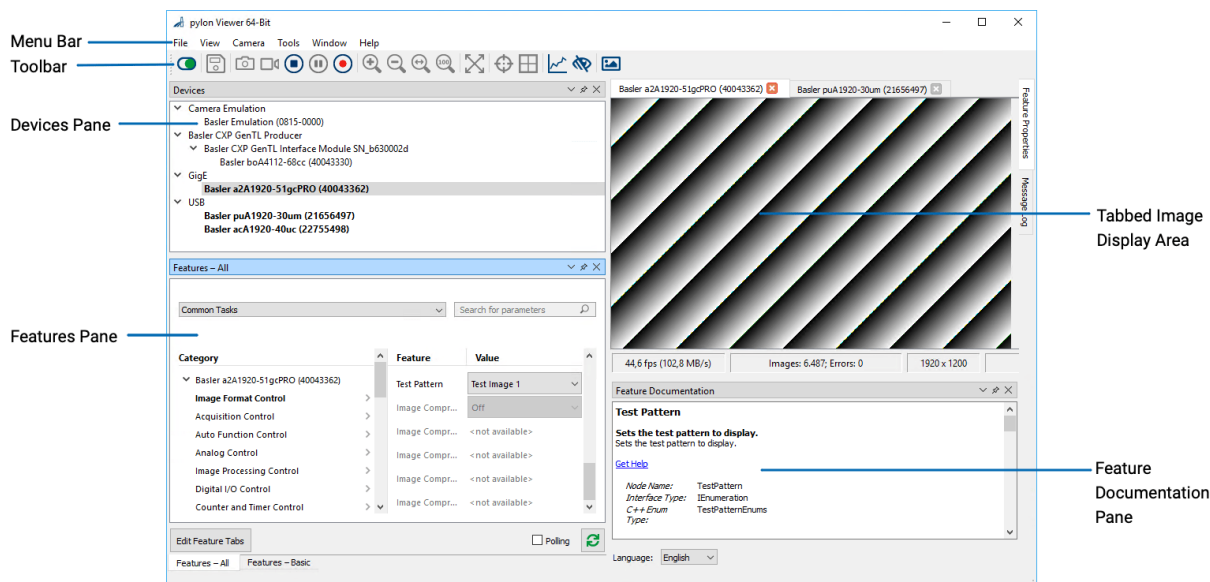
Při realizaci řešení daného problému je zvolen tento postup:

1. Sestavení hardwarových částí podle schématu
2. Nastavení intenzity RGB na 150 pro každou složku.
3. Vložení růžového listu papíru jako podklad (doplňková barva)
4. Spuštění Pylon Viewer na PC připojeném ke kameře.
5. Postupné vkládání jednotlivých kabelů a pořizování jejich fotografií.
6. Vytvoření datasetu z pořízených snímků a jejich klasifikace za pomoci CNN.

SOFTWARE

Záznam fotek

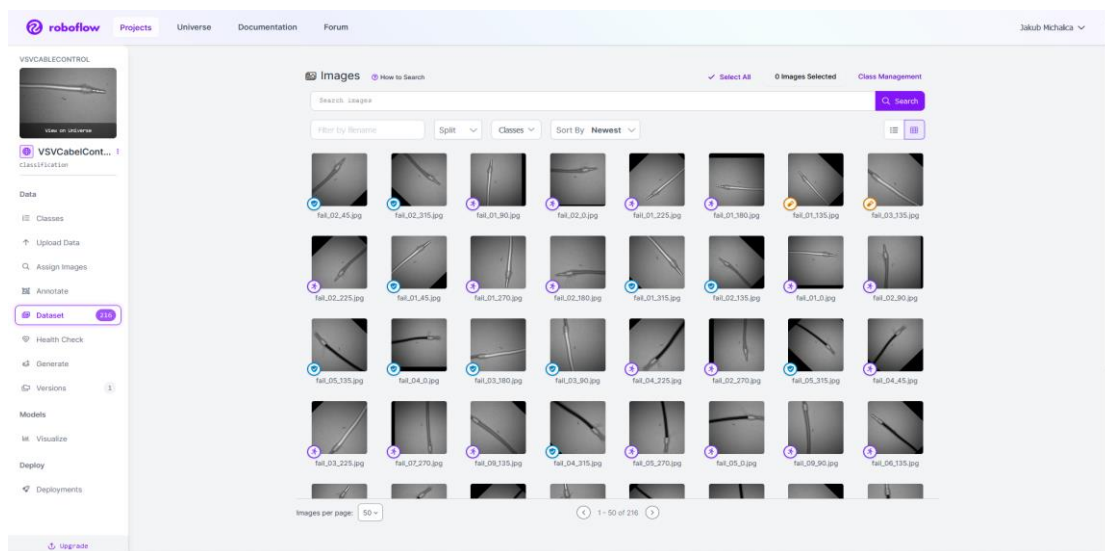
Pylon Viewer od Basler pylon Camera Software Suite byl použit pro záznam fotek z kamery.



Obr. 5 Pylon Viewer

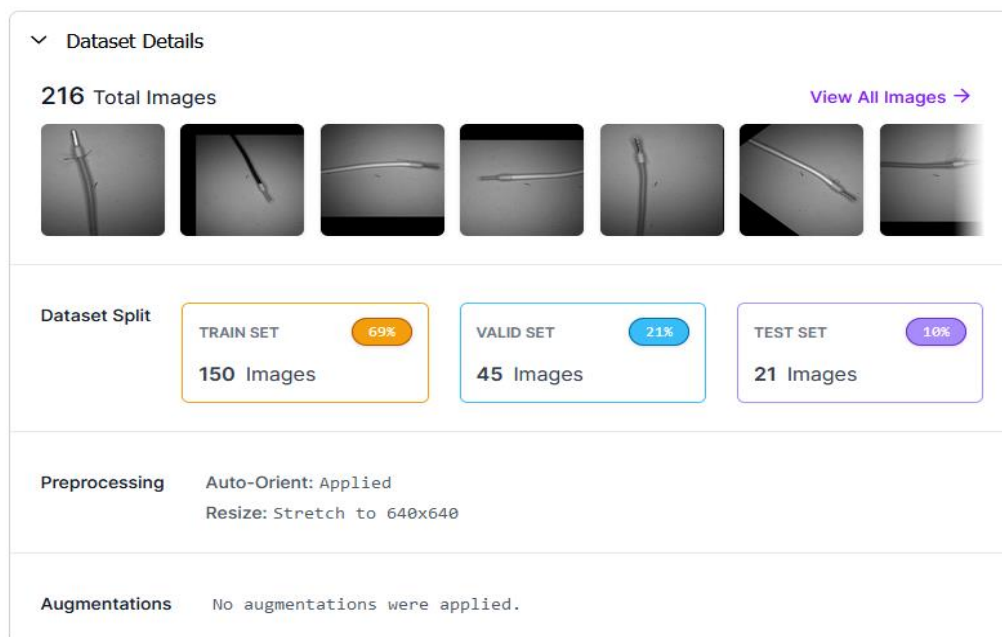
Dataset a trénink

Dataset byl rozšířen pomocí rotace obrázků po 45° a náhodného malého zvětšení (1x - 1.5x). Následně byla provedena pomocí prostředí Roboflow, které umožňuje kolaboraci více osob při anotaci datasetu.




Obr. 6 Anotovaný dataset

Dataset byl následně náhodně rozdělen na 69% trénovací, 21% validační a 10% testovací setů obrázků.



Obr. 7 Rozdělení dataset

Trénink neuronové sítě byl také proveden v prostředí Roboflow, protože poskytuje možnost trénovat na vzdáleném hardware, který byl díky tomu mnohem rychlejší než kdybychom trénovali lokálně na notebooku. Model neuronové sítě je proprietární konvoluční síť Roboflow 2.0 Classification vycházející z architektury ImageNet.



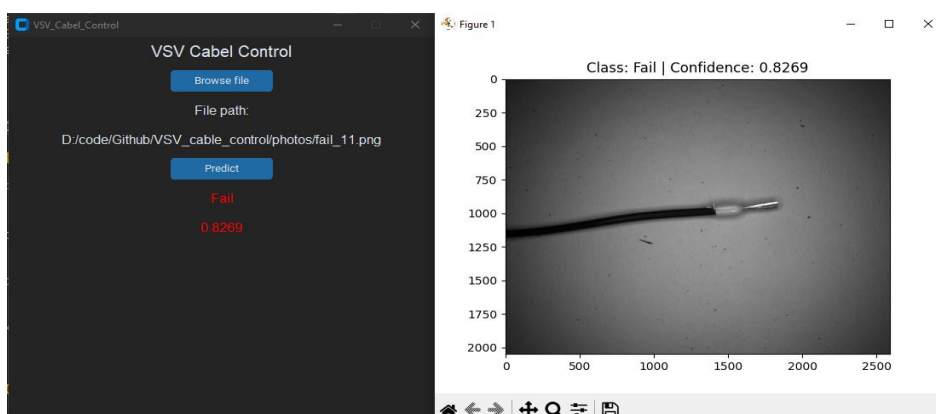
Obr. 8 Priebeh tréovania

Natrénovanou sít lze následně použít a nasadit mnoha různými způsoby. Roboflow poskytuje možnosti použití jejich serverů nebo poskytuje podporu pro Docker kontejnery což nabízí možnost nasazení na vlastním hardware nebo embedovaném zařízení typu NVIDIA Jetson, Raspberry Pi.

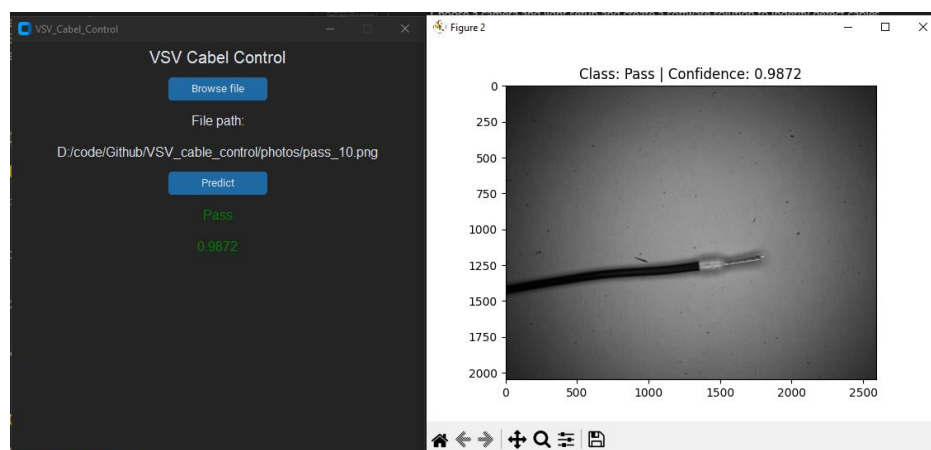
Vlastní software

Námi vytvořený GUI nástroj slouží k demonstraci správnosti funkce neuronové sítě a poskytuje jednoduché uživatelské rozhraní pro nahrání fotky a její klasifikaci za použití RoboFlow API.

V případě opravdového nasazení by bylo lepší použít například výše zmíněný NVIDIA Jetson nebo Raspberry Pi.



Obr. 9 Ukážka GUI pre "Fail"



Obr. 10 Ukážka GUI pre "Pass"

ZÁVĚR

Úspěšnost natrénovaného modelu se ve finále pohybuje kolem 80%, což vzhledem k malému datasetu považujeme za velmi slušnou hodnotu. Bylo nutné čelit i další komplikaci a to čistotě objektivu, který nepříznivě ovlivňoval pořízené snímky (někdy nešlo rozpoznat zdali se jedná o otřep nebo jen o nečistotu). Další limitací je neschopnost detekovat otřepy nacházející se pod kabelem, pro jejich detekci by bylo potřeba kabelem otáčet nebo mít k dispozici více kamer.